

Material Suplementario — Métodos y Resultados Extendidos

Análisis multicapa de operadores de PostgreSQL y almacenamiento CSI en Kubernetes: estudio empírico de CloudNativePG bajo fallos inyectados (Fase 1)

Herrera, M. Parejo, A.

Universidad de Carabobo, Valencia, Venezuela

Correspondencia: Parejo, A. — ORCID 0009-0001-9737-7116

Nota. Este documento acompaña al artículo homónimo enviado a la Revista FARAUTE de Ciencias y Tecnología (UC/FACYT) y forma parte del depósito de reproducibilidad (Zenodo, DOI: 10.5281/zenodo.23004248). Recoge el detalle metodológico y estadístico que, por el límite de extensión del artículo, no cabe en el cuerpo principal, y documenta explícitamente los puntos que un árbitro necesita para auditar los resultados. Todas las cifras aquí y en el artículo se reproducen ejecutando `execution-package/manifiestos/scripts/analyze.py` sobre los CSV de `data/`.

S1 Propósito y alcance

La Fase 1 caracteriza empíricamente el comportamiento de CloudNativePG (CNPG) 1.28.0 bajo tres escenarios de fallo reproducibles de forma segura en un clúster productivo: F1 (*pod-kill*), F2 (*pod-failure*) y F3 (partición de red), más un F4 (latencia de E/S) no ejecutable. El análisis es descriptivo (medianas, rangos intercuartílicos e intervalos de confianza de mediana) más un único contraste de dos grupos intra-CNPG (F1 vs. F2). Este suplemento amplía las Secciones 5 y 6 del artículo.

S2 Metodología extendida

S2.1 Entorno

Kubernetes v1.34.6; PostgreSQL 16.13; CNPG 1.28.0; Chaos Mesh 2.8.3; Calico 3.31.4; almacenamiento CSI Huawei 4.10.1 (`csi.huawei.com`) sobre *Fibre Channel* (SAN); *StorageClass* con *Retain* y *WaitForFirstConsumer*. Entorno *air-gapped*: imágenes importadas localmente.

S2.2 Aislamiento (tres controles + malla)

El clúster experimental se fijó por afinidad al nodo de laboratorio, compartido con otras cargas. El aislamiento no descansó en la exclusividad del nodo sino en: (i) Chaos Mesh restringido al espacio de nombres; (ii) doble filtro de selección (espacio de nombres + nombre de clúster) en cada manifiesto de fallo; (iii) verificación previa (*dry-run*) que confirmó, para cada selector, resolución exclusiva a los pods del clúster experimental. Además, los pods se excluyeron de la malla (Linkerd) para no introducir un *proxy* en la ruta de datos que sesgara RTO/latencia.

Cuadro S1: Análisis de sensibilidad de la exclusión de F2 (arranque en frío).

Conjunto F2	n	Mediana (s)	Brecha F2–F1 (s)
Analizado (sin arranque en frío)	10	36,75	28,84
Con la 1. ^a inyección ($\approx 80,5$ s)	11	36,92	29,01

Incluir el punto excluido eleva la mediana de F2 y *ensancha* la brecha respecto a F1 (mediana 7,91 s). La exclusión es, por tanto, conservadora.

S2.3 Verificador de transacciones (tx-verifier) y semántica ante ACK perdido

El verificador inserta identificadores BIGINT monótonos generados por un contador de cliente y anota cada COMMIT con marca de tiempo. Ante un fallo **reintenta el mismo identificador** (no avanza el contador), de modo que los cortes no crean huecos artificiales y un hueco en la tabla de verdad equivale a una escritura reconocida y perdida (proxy del RPO por contigüidad de la secuencia).

Esto resuelve el caso frontera de un COMMIT *confirmado pero no reconocido* (el primario persistió la fila pero el ACK se perdió por el corte): al reintentar el mismo id, un error de **clave duplicada** revela que la escritura *sí* había persistido (“commit fantasma”). El verificador detecta el duplicado y lo contabiliza como escritura persistida, no como pérdida; por eso el RPO no se sobreestima. El mecanismo está en el manifiesto `execution-package/manifiestos/30-workload/tx-verifier-cnpg.yaml` (la línea que reintenta el mismo id y detecta el duplicado como *commit fantasma*).

S2.4 Granularidad y precisión de medición

El verificador opera en bucle apretado sin espera entre escrituras exitosas; ante un fallo aplica una espera de 0,2 s y un `PGCONNECT_TIMEOUT` de 2 s. La **granularidad de medición del RTO** (hueco entre COMMIT consecutivos) es, por tanto, $\approx 0,2$ s. Las marcas de tiempo de COMMIT tienen resolución de milisegundos; la incertidumbre sistemática en el punto de recuperación es de $\pm 0,2$ s (la cadencia del sondeo). Las cifras a dos decimales deben leerse con esa incertidumbre.

S3 Escenarios, muestra y exclusiones

F1 y F2: $n = 10$ cada uno. F3: 10 inyecciones fijas de 60 s (usadas en el RTO) más 2 exploratorias (149 s y 300 s) excluidas del cálculo del RTO; no-promoción observada en las 12 (0/12). El tamaño muestral responde a las ventanas de mantenimiento del clúster productivo; no se hizo cálculo formal de potencia. Dada la no-normalidad esperada, se reportan medianas e IQR.

Exclusiones (transparencia). Se excluyeron: (a) la 1.^a inyección de F2 ($\approx 80,5$ s, arranque en frío: caché fría, cola de reconciliación no calentada, primer ciclo de recreación); (b) las 2 inyecciones exploratorias de F3; (c) un identificador espurio negativo de un arranque previo. La exclusión (a) es **conservadora respecto al hallazgo principal**: incluir los 80,5 s *amplía* la brecha F1–F2 (Tabla S1), luego no favorece la tesis.

S4 Estadística completa

Todas las cantidades se reproducen con `analyze.py` (biblioteca estándar de Python).

Descriptivos. F1: mediana 7,91 s, IQR [7,62, 8,01], rango [6,61, 8,17]. F2: mediana 36,75 s, IQR [36,20, 37,06], rango [35,51, 38,32]. Razón de medianas $F2/F1 = 4,65\times$.

Intervalos de confianza de mediana (distribución-libre). Con $n = 10$ se usan los estadísticos de orden 2.º y 9.º, $[x_{(2)}, x_{(9)}]$, con cobertura

$$1 - 2 \sum_{k=0}^1 \binom{10}{k} 0,5^{10} = 0,9785 (\approx 97,9\%).$$

Resulta: F1 [6,85, 8,15] s; F2 [36,05, 37,66] s; F3 fija [60,74, 60,77] s.

Contraste F1 vs. F2. Mann–Whitney $U = 0$ (separación total, sin solapamiento). El p exacto bilateral es

$$p = \frac{2}{\binom{20}{10}} = \frac{2}{184756} = 1,083 \times 10^{-5},$$

que es el **piso teórico** alcanzable con $n = 10$ por grupo: el test está saturado y el peso probatorio recae en el tamaño de efecto y el mecanismo, no en la magnitud del p . Aproximación normal: $z = -3,78$ ($p \approx 1,6 \times 10^{-4}$). Correlación rango-biserial = 1,00. Diferencia de medianas resistente (Hodges–Lehmann) = 28,96 s.

Prueba de permutación (robustez ante no-independencia). Las 10 repeticiones se ejecutaron en serie; en F2 hay una asociación débil orden–RTO (Spearman $p \approx 0,62$, valor crítico exacto para $n = 10$ a $\alpha = 0,05$ es 0,648; *no* significativa). Como el test de Mann–Whitney es él mismo una prueba de permutación y la separación entre grupos es *total*, cualquier reordenamiento admisible que respete los bloques mantiene $U = 0$; el p de permutación coincide con $2/\binom{20}{10}$. La conclusión no depende, pues, del supuesto de intercambiabilidad.

No-promoción (Clopper–Pearson). Cota superior **unilateral** al 95 % con 0 éxitos: $1 - 0,05^{1/n}$. F2 (0/10): $\leq 25,9\%$. F3 (0/12): $\leq 22,1\%$. (La cota bilateral al 95 % sería 30,8% y 26,5%.) La conclusión de no-promoción se apoya sobre todo en el mecanismo observado, no solo en el conteo.

RPO nulo: mecanismo. El RPO fue 0 en los tres escenarios; solo F1 lo pone a prueba de forma no trivial (hay promoción real). Con replicación asíncrona, un *pod-kill* podría en principio descartar WAL confirmado no propagado; que no ocurriera en 10/10 se atribuye a un retardo de replicación (*lag*) ≈ 0 bajo carga ligera (pgbench -s 10, 4 clientes). **Es una inferencia de mecanismo, no una medición:** no se registró el LSN *lag* durante las corridas (medición asignada a la Fase 2). La co-localización intra-nodo implica además que la replicación no atravesó red inter-nodo, por lo que el RPO=0 de F1 no prueba todavía la durabilidad ante partición o latencia inter-nodo reales.

S5 F4 (IOChaos / FUSE): bloqueo de instrumentación

El escenario F4 (sensibilidad del RTO a latencia de E/S de 0, 20, 50 y 100 ms vía IOChaos) **no fue ejecutable** sobre CNPG. El inyector FUSE toda de Chaos Mesh hizo *ptrace attach* sobre PostgreSQL, pero al montar el sistema de archivos FUSE falló con Read-only file system (os error 30) y entró en reinicios. Causa: CNPG endurece sus pods con `readOnlyRootFilesystem: true` (junto con `runAsNonRoot` y descarte de capacidades), mientras que toda requiere una raíz escribible para su andamiaje de montaje.

La configuración era correcta (el *dry-run* de selectores resolvió solo a los pods del clúster experimental; el PodIOChaos llevaba ruta, contenedor y parámetros correctos): es una **incompatibilidad**, no un error de configuración. Es una limitación de este par de herramientas, no una propiedad general. Dos vías para la Fase 2: (i) test confirmatorio desactivando `readOnlyRootFilesystem` para aislar la causa; (ii) limitación de ancho de banda de E/S a nivel de *cgroup* (`io.max`), que no depende de FUSE ni modifica el sistema bajo prueba. Los manifiestos de F4 se incluyen en el depósito para referencia.

S6 Limitaciones extendidas

- **Un operador, una categoría de almacenamiento:** solo CNPG sobre CSI en red (SAN/FC). La comparación con Zalando/Patroni y Crunchy es analítica (Tabla 1 del artículo) y se asigna a la Fase 2.
- **Topología co-localizada:** las tres instancias residieron en un único nodo elegible; el *failover* es intra-nodo y un fallo de nodo completo no es *testable* por construcción. El RTO de F2 es una **cota inferior** del real ante pérdida de nodo (no captura la latencia *detach/attach* del volumen CSI).
- **Carga pequeña:** `pgbench -s 10` (≈ 150 MB), 4 clientes: no es un peor caso; central para el *lag* ≈ 0 y el RPO=0.
- **Solo asíncrono:** el modo síncrono no se varió; las cifras de RPO corresponden a replicación asíncrona.

Disponibilidad

Datos limpios, manifiestos, `tx-verifier`, scripts y este suplemento se depositan en Zenodo (DOI: 10.5281/zenodo.23004248, CC-BY-4.0; código MIT). Los registros crudos del verificador y los eventos del operador se facilitan a petición por el acceso restringido del clúster productivo.